Lab2 Part2 314551126 林正峰

1. 結果總覽

Case	Compression Ratio	PPL
1	75.208743%	14.8505
2	81.873929%	16.1482
3	50%	25.7291
4	86.276105%	18.8324

2. 壓縮率說明

36 個 decoder block，而每個 block 有 7 個 Linear：q_proj、k_proj、v_proj、o_proj、gate_proj、up_proj、down_proj，這 252 個 linear block，共有 3,633,315,840 個權重每個 FP16 權重占 16 bits，也就是 2 bytes，因此分母為: 7,266,631,680 bytes。而分子則為這 252 層壓所後的結果，加上各自方法所需的額外空間。

3. Case1

甲、Compression Strategy:

Case 1 我先把 Qwen3-4B decoder 的 Linear 全部用 NF4 加 double quantization 壓成 4-bit，作為低失真的 baseline。不過因為 NF4 還需要儲存 scale 和 quantization state，所以實際壓縮率會略低於理論上的 75%。因此我再從 MLP 的 gate、up、down projection 中挑部分層改成 packed GPTQ 3-bit。挑選方式不是固定指定 layer，而是用 WikiText-2 train 做 calibration。32 組 512-token 資料用來估計 input Gram matrix，提供 GPTQ 的 Hessian-aware error compensation；另外 4 組 holdout data 分別測量 NF4 和 GPTQ3 對每個 Linear 輸出的 reconstruction error。
最後我計算每個 layer 從 NF4 改成 GPTQ3 所增加的誤差，除以實際能節省的 bytes，優先替換 cost 最低的 layer，直到 compression ratio 超過 75.2%。最後官方測試得到 75.2087% compression ratio，PPL 14.8505。。

乙、Result

項目	Case 1 結果	題目要求
Decoder Linear 總數	252	
GPTQ 3-bit Linear 數	25	
NF4 Linear 數	227	
原始 Linear payload	7,266,631,680 bytes	
壓縮後 Linear payload	1,801,489,343 bytes	
Compression Ratio	75.2087%	> 75%

PPL	14.8505	< 15

丙、Analysis

若全部 252 個 decoder Linear layers 都使用 NF4，即使每個 weight 名義上是 4-bit，實際上還需要儲存 scale、double-quantization state、codebook 等額外資訊，因此實測 Linear payload 為 1,874,632,819 bytes，Compression Ratio 只有 74.2022%，無法達到題目要求的 75%。這說明只按照理論 bit-width 計算並不足夠，必須把所有附加 tensor 的實際儲存空間一併考慮。

為了跨過 75% 門檻，本方法將 25 個 MLP Linear 從 NF4 改為 packed GPTQ 3-bit。每個被替換的 MLP Linear 約可再節省 2.93 MB，25 層合計節省 73,143,476 bytes，使 Compression Ratio 增加約 1.0066 個百分點，從 74.2022% 提升至 75.2087%。最終選出的 25 層包含 16 個 gate_proj、5 個 up_proj 與 4 個 down_proj，表示 layer 的選擇是由 calibration error 與實際 byte saving 共同決定，而不是對特定 projection 類型使用固定規則。

在選出的 25 個 layers 中，有 12 個 layer 的 GPTQ 3-bit holdout output reconstruction error 甚至低於 NF4，顯示 GPTQ 的 Hessian-aware error compensation 在部分 layers 中可以用較少 bits 得到較低的局部輸出誤差。其餘 13 個 layers 雖然改成 3-bit 後誤差增加，但它們是在剩餘候選中「每節省一個 byte 所增加的誤差」較小者。因此，此策略並不是任意將大量 layers 降為 3-bit，而是優先利用對模型輸出影響較小的壓縮機會。

最終仍有 227 個 decoder Linear 保留 NF4，只有約 9.9% 的目標 Linear 使用 GPTQ 3-bit；其中 attention projections 全部維持 NF4，較積極的 3-bit 量化只套用於經 calibration ranking 選出的 MLP projections。這種配置限制了低位元量化影響的範圍，使模型在達到 75.2087% Compression Ratio 的同時，PPL 仍維持在 14.8505，符合題目要求的 PPL < 15。不過，最終結果距離兩個門檻都不遠：Compression Ratio 僅比 75% 高 0.2087 個百分點，而 PPL 僅比 15 低 0.1495。這反映 Case 1 的設計是在壓縮率與模型品質之間取得接近邊界的配置。Calibration 時使用的 layer output reconstruction error 只是 PPL sensitivity 的近似指標，無法保證局部誤差較低一定會帶來較低的整體 PPL，因此最後仍需要以官方 WikiText-2 test evaluation 確認配置是否真正符合要求。

4. Case2

甲、Compression Strategy:

Case 2 採用 GPTQ INT2／INT3 mixed-precision quantization。首先將全部 252 個 decoder Linear 量化為 GPTQ 3-bit，作為較低誤差的 baseline；由於實際儲存還包含 scale、zero point 與排列索引等資訊，僅使用 3-bit 無法提供足夠的壓縮餘裕，因此再選擇部分 Linear 進一步由 3-bit 降至 2-bit。

每個 Linear 都建立 GPTQ 3-bit 與 2-bit 候選。使用 WikiText-2 train 的 64 × 1024 tokens 建立 GPTQ 所需的輸入統計，另保留 8 × 1024 tokens 評估候選。對每個 Linear，分別比較「全部 3-bit」與「僅該 Linear 改為 2-bit」時所在 decoder block 的輸出 reconstruction error，找哪些 Linear 進一步降為 2-bit 時，每節省單位儲存空間所造成的額外誤差越小，因此優先採用 2-bit，直到整體 Compression Ratio 達到預設目標。

乙、Result

設定	CR	PPL
Case2	81.873929%	16.1482

丙、Analysis

若全部 252 個 decoder Linear layers 都使用 packed GPTQ 3-bit，實際 Linear payload 為 1,408,905,216 bytes，Compression Ratio 為 80.6113%。這已經接近題目要求的 81%，但仍不足以通過門檻，也沒有留下執行環境或儲存格式差異的安全餘裕。因此，本方法進一步將部分較不敏感的 Linear 由 3-bit 降為 2-bit，並將目標設為約 81.87%，而不是只停在剛好 81%。

最終共有 44 個 Linear 使用 GPTQ 2-bit，其餘 208 個維持 GPTQ 3-bit。這 44 個 layers 額外節省 91,750,400 bytes，使 Linear payload 從 1,408,905,216 bytes 降至 1,317,154,816 bytes，Compression Ratio 增加約 1.2626 個百分點，最終達到 81.8739%。相較題目要求的 81%，保留了約 0.8739 個百分點的餘裕。

被選為 2-bit 的 layers 並不集中於單一 projection 類型，而是包含 16 個 q_proj、13 個 gate_proj、6 個 o_proj、4 個 up_proj、3 個 down_proj 與 2 個 k_proj，其中共有 24 個 attention projections 與 20 個 MLP projections。這表示配置不是預先假設某一類 layer 一定較不重要，而是依據 calibration holdout 上的 block output reconstruction error，以及每個候選實際能節省的 bytes 進行選擇。沒有任何 v_proj 被降為 2-bit，也反映在目前的 calibration ranking 中，v_proj 並不是最適合進一步降低精度的候

選；但這只能解讀為本次 calibration 資料與評分方式下的結果，不能推論所有模型的 v_proj 都較敏感。

在 44 個被選中的 candidates 中，有 3 個 layer 改為 2-bit 後，量測到的 decoder block output error 反而比全 3-bit baseline 更低。這可能來自不同量化誤差在 block 內互相抵銷，不代表 2-bit 本身一定比 3-bit 精確。其餘 41 個 candidates 的 block output error 都有所增加，但它們是在所有剩餘候選中「每節省一個 byte 所增加的誤差」較小者。因此，mixed-precision allocation 能將較大的精度損失限制在 calibration 判定影響較小的 layers，而不是把全部 252 個 Linear 一律降為 2-bit。

最終 PPL 為 16.1482，符合題目要求的 PPL < 20。相較 Case 1，Case 2 的 Compression Ratio 從 75.2087% 提升至 81.8739%，增加約 6.6652 個百分點；同時 PPL 從 14.8505 上升至 16.1482，增加 1.2977。雖然兩個 cases 使用的量化配置與 calibration 方法不同，不能把 PPL 差異完全歸因於 bit-width，但結果仍呈現預期的整體趨勢：使用更多 2-bit weights 能得到更高壓縮率，同時也會增加 weight reconstruction error，使模型品質下降。

此外，2-bit quantization 每個 group 只能使用 4 個量化值，數值解析度明顯低於 3-bit 的 8 個量化值。即使 GPTQ 使用 input statistics 與 error compensation 降低誤差，當 44 個 layers 同時使用 2-bit 時，誤差仍會在多層 Transformer blocks 中傳播並累積，因此 PPL 高於 Case 1 是合理結果。不過，最終 PPL 仍比門檻 20 低 3.8518，表示以 block output error ／saved bytes 排序的策略成功在較高壓縮率下保留了足夠的模型品質。

需要注意的是，calibration holdout 上的 block reconstruction error 仍只是最終 PPL sensitivity 的近似指標。局部 block error 較低不一定保證完整模型的 WikiText-2 PPL 較低，因此最後仍必須以官方 test set evaluation 驗證。此次結果顯示，GPTQ INT2／INT3 mixed precision 能在實際計入 scales、zero points 與排列索引後，達到 81.8739% Compression Ratio，並將 PPL 維持在 20 以下。

5. Case3

甲、Compression Strategy:

Case 3 採用 Activation-weighted SVD + INT8/FP16 mixed precision，分成兩個階段完成。第一階段先利用 SVD 降低部分 MLP Linear 的矩陣維度，使 SVD Compression Ratio ≥ 20%；第二階段再將部分 weight rows 由 FP16 量化為 INT8，使最終 Overall Compression Ratio 精確達到 50%。

使用 WikiText-2 train 的 64 × 1024 tokens 收集 calibration statistics，另保留 8 × 1024 tokens 進行誤差評估。SVD 僅套用於各 decoder block 的 gate_proj、up_proj 與 down_proj。

對每個 Linear (y=Wx)，除了考慮原始權重 (W) 外，也利用 calibration activation 使低秩分解優先保留對實際輸出較重要的方向。

當 rank (r) 降低時，(A) 與 (B) 的總參數量減少，但 reconstruction error 會增加。因此每個候選 Linear 從 rank 1024 開始，以 64 為間隔測試多個 rank，並根據「增加的輸出誤差／節省的 bytes」分配較適合的 rank，直到 SVD 壓縮率達到目標。

SVD 後仍未達 Overall Compression Ratio = 50%，因此第二階段進一步對剩餘 dense Linear 以及 SVD 產生的 (A)、(B) factors 進行 per-row INT8 quantization。

每個 INT8 row 使用 INT8 weights 並額外儲存一個 FP16 scale；程式先以 calibration input 評估各個 dense Linear 或 SVD factor component 完整轉為 INT8 時的輸出 reconstruction error，再以「component error／最大可節省 bytes」排序。誤差成本較低的 components 優先轉換較多 rows；為了精確符合 byte target，邊界 components 只轉換部分 rows，其餘 rows 保留 FP16。配置依據 calibration input 上的輸出 reconstruction error 與可節省的 bytes 決定。

最後依實際 tensor payload 配置 INT8 與 FP16 rows，使壓縮後 Linear payload 精確等於原始大小的 50%。

乙、Result

階段	目標 Linear bytes	CR
原始 FP16	7,266,631,680	0%
僅 SVD	5,648,154,624	22.272727%
SVD＋INT8／FP16	3,633,315,840	50%

丙、Analysis

第一階段的 Activation-weighted SVD 將 69 個 MLP Linear matrices 分解為兩個較小的 low-rank factors，使目標 Linear payload 從 7,266,631,680 bytes 降至 5,648,154,624 bytes，共節省 1,618,477,056 bytes，SVD Compression Ratio 為 22.2727%，符合題目要求的 SVD Compression Ratio ≥ 20%。

被分解的 69 個 matrices 包含全部 36 個 gate_proj、26 個 up_proj 與 7 個 down_proj。這個分布不是事先固定，而是由 calibration activation 上的輸出 reconstruction error 與 saved bytes 共同決定。在本次 ranking 中，

gate_proj 最常被選擇，而 down_proj 只有 7 個被選擇，表示在相同的壓縮效益下，多數 down_proj 的低秩近似誤差較高，因此不適合優先進行 SVD。不過，這項觀察只代表本次模型與 calibration samples 下的結果，不能直接推論所有模型的 down_proj 都較敏感。

Rank 配置同樣反映壓縮率與 reconstruction error 的取捨。69 個 low-rank matrices 中，有 51 個使用 rank 1024，其餘則使用較高的 rank：4 個 rank 1088、3 個 rank 1152、4 個 rank 1216、5 個 rank 1280，以及 2 個 rank 1344。較低的 rank 可以節省更多 bytes，但會捨棄更多原始 weight matrix 的方向；較高的 rank 則保留較多資訊，但壓縮效果較小。因此，較敏感的候選會停在較高 rank，而 calibration error 較低的候選可以使用較低 rank。

SVD 階段已達到題目要求的 20%，但 22.2727% 距離最終指定的 50% 仍有很大差距。若繼續只靠降低 rank 達到 50%，需要在更多 matrices 上使用更低 rank，可能造成較嚴重的結構性資訊損失。因此第二階段保留既有 SVD 結構，改以 per-row INT8／FP16 mixed precision 補足剩餘壓縮量。

SVD 後共有 321 個可量化 components，包括未分解的 dense Linear，以及 69 個 low-rank Linear 所產生的 left、right factors。第二階段將其中約 20.17 億個 weight values 以 INT8 儲存，占 SVD 後 weight elements 約 71.41%；每個 INT8 row 另外儲存一個 FP16 scale。最終有 146 個 components 的全部 rows 使用 INT8、171 個 components 完全保留 FP16，另有 4 個 components 使用部分 INT8 rows 與部分 FP16 rows。

這種配置讓 reconstruction error 較低、每 byte 壓縮效益較高的 components 優先使用 INT8，而較敏感的 components 保留 FP16。對一個長度為 n 的 row 而言，原始 FP16 需要 2n bytes；轉為 INT8 後需要 n bytes 的 weights 與 2 bytes 的 FP16 scale，因此每轉換一個 row 可實際節省 n-2 bytes。程式依照這個實際 byte saving 分配 INT8 rows，而不是只用理論上的 8-bit 對 16-bit 估算。

第二階段額外節省 2,014,838,784 bytes，使 payload 從 5,648,154,624 bytes 降至 3,633,315,840 bytes。這個數值正好是原始 7,266,631,680 bytes 的一半，因此最終 Compression Ratio 為精確的 50%，不是經過四捨五入後的近似值。SVD 約貢獻全部節省空間的 44.55%，INT8／FP16 mixed precision 則貢獻約 55.45%。

最終 PPL 為 25.7291，符合題目要求的 PPL < 50，但明顯高於 Case 1 與 Case 2。這表示模型品質不只取決於 Compression Ratio，也與壓縮方法所造成的誤差形式有關。GPTQ 主要是在保留原始矩陣維度的情況下降低 weight precision；SVD 則直接捨棄部分矩陣子空間，即使使用 activation-weighted basis，仍可能移除對未見 test data 有用的方向。尤其本實驗有 51 個 matrices 使用 rank 1024，低秩近似造成的結構性誤差會經過多層 MLP 累積。

第二階段的 INT8 quantization 又在 SVD approximation 之上加入 rounding error。雖然 per-row scale 能讓不同 rows 使用各自的量化範圍，而且高誤差 components 可保留 FP16，但約 71.41% 的 SVD 後 weight elements 最終以 INT8 儲存，仍會進一步影響模型輸出。因此，Case 3 較高的 PPL 是 low-rank approximation 與 INT8 quantization 兩種誤差共同作用的結果。

整體而言，此兩階段策略成功同時滿足三個限制：SVD Compression Ratio 為 22.2727%，高於 20%；Overall Compression Ratio 精確等於 50%；最終 PPL 25.7291，低於 50。結果也顯示，SVD 能提供實際的結構性壓縮，但相較單純降低 weight bit-width，更容易造成模型品質下降，因此需要透過 activation-weighted rank selection 與 INT8／FP16 mixed precision 控制誤差。

6. Case4

甲、Compression Strategy:

Case 4 採用 Structured MLP Pruning + GPTQ INT2/INT3 mixed quantization。先實際刪除部分 MLP hidden neurons，使 Pruning Rate ≥ 20%，再對剪枝後模型重新進行 GPTQ calibration 與低位元量化。

MLP 中間 activation 定義為：z = SiLU(gate(x)) × up(x), 第 j 個 neuron 的重要度為：Importance(j) = E[z_j^2] × ||W_down[:, j]||_2^2

重要度較低的 neuron 優先被移除。刪除一個 neuron 時，會同步刪除 gate_proj、up_proj 對應的 row，以及 down_proj 對應的 column，因此模型結構與參數量會實際縮小。

每個 decoder block 測試不同保留寬度 7424、7168、6912、6656、6400，並比較直接剪枝與補償後的 block output error，選擇較低誤差的方案。不同 block 依「增加的 error / 移除的 weights」決定剪枝程度。

剪枝完成後重新收集 calibration statistics，再以 GPTQ 3-bit 為 baseline，將部分較不敏感的 Linear 降為 2-bit。

乙、Result

設定	CR	PPL
先前剪枝 FP16 控制實驗	22.4567%	16.1005
本次剪枝＋INT2／INT3	86.276105%	18.8324

丙、Analysis

第一階段的 structured pruning 從原始 3,633,315,840 個 decoder Linear weights 中實際移除 815,923,200 個 weights，剩下 2,817,392,640 個 weights，Pruning Rate 為 22.4567%，符合題目要求的 Pruning Rate ≥ 20%。以 FP16 儲存時計算，目標 Linear payload 由 7,266,631,680 bytes 降至 5,634,785,280 bytes。

本方法不是將所有 MLP blocks 剪成相同寬度，而是根據 calibration activation 與 block output error 分配不同的保留寬度。36 個 decoder blocks 中有 33 個實際縮小 MLP hidden width，另外 3 個 blocks 保留原始寬度 9728。被剪枝的 33 個 blocks 中，28 個縮小至 6400、2 個縮小至 6656、3 個縮小至 7424。沒有 block 最終採用候選寬度 6912 或 7168，表示在本次「增加的 block error／移除的 weights」排序下，這兩種中間寬度沒有形成較佳的整體配置。

剪除一個 MLP neuron 時，程式會同步刪除 gate_proj 與 up_proj 的對應 row，以及 down_proj 的對應 column，因此這些 weights 是從模型結構中實際移除，而不是以 mask 設為零。這使 pruning 能直接降低後續需要量化與儲存的參數量，也減少 MLP inference 中對應的計算維度。

在 33 個被剪枝的 blocks 中，有 32 個採用補償後的結果，只有 1 個使用未補償的直接剪枝。對這些已選方案記錄的 normalized block-output error 加總後，直接剪枝約為 0.03513，補償後約為 0.02546，降低約 27.54%。這表示只依 neuron importance 刪除較不重要的維度仍會改變 block output，而補償程序能利用保留的 weights 吸收部分被刪除 neurons 的影響，降低 structured pruning 對模型品質的破壞。

剪枝後的 FP16 控制實驗 PPL 為 16.1005。這表示在移除 22.4567% decoder Linear weights 後，模型仍保留足夠的語言模型能力，也說明 activation-based neuron importance、不同 block 的寬度分配與補償程序確實能避免任意剪枝造成的大幅品質下降。因此，structured pruning 除了直接

滿足 Pruning Rate 要求，也為第二階段低位元量化提供較小且仍可使用的模型。

第二階段先將剪枝後的全部 252 個 Linear 量化為 GPTQ 3-bit。由於 MLP matrices 已經縮小，全 3-bit baseline 的實際 Linear payload 為 1,092,947,456 bytes，相對原始未剪枝 FP16 Linear 的 Compression Ratio 為 84.9594%。這個結果只比題目要求的 85% 少約 0.0406 個百分點，顯示 structured pruning 與 3-bit quantization 的組合已非常接近門檻，但仍不能直接視為通過。

為了跨過 85% 並保留安全餘裕，本方法再將 61 個 Linear 從 GPTQ 3-bit 降為 2-bit，其餘 191 個維持 3-bit。這 61 個 layers 額外節省 95,682,560 bytes，使 payload 從 1,092,947,456 bytes 降至 997,264,896 bytes，Compression Ratio 增加約 1.3167 個百分點，最終達到 86.2761%。

被選為 2-bit 的 61 個 layers 包含 21 個 q_proj、15 個 gate_proj、14 個 o_proj、6 個 up_proj、3 個 down_proj 與 2 個 k_proj，其中 37 個屬於 attention projections，24 個屬於 MLP projections。這表示剪枝後的 mixed-precision 配置並未只繼續壓縮 MLP，而是根據重新收集的 calibration statistics，從整個剪枝後模型選擇「每節省一個 byte 所增加的 block output error」較低的 INT2 candidates。

61 個 INT2 candidates 中，有 2 個 layer 在 holdout data 上量測到的 block output error 低於全 INT3 baseline，可能來自不同量化誤差在 block 內互相抵銷；其餘 59 個 candidates 的 error 都有所增加，但它們是排名中誤差成本較低者。這不代表 INT2 本身比 INT3 更精確，而是說在目前的 calibration samples 下，這些 layers 是相對適合降低 bit-width 的選擇。

最終量化後 PPL 為 18.8324，相較 pruning-only FP16 控制實驗的 16.1005 增加 2.7319。這段差異主要反映剪枝後再套用 GPTQ INT2／INT3 所加入的 weight reconstruction error。2-bit 每個 group 只能使用 4 個量化值，數值解析度明顯低於 3-bit；而且有 61 個 layers 使用 INT2，因此量化誤差會經過多層 attention 與 MLP 累積。不過，最終 PPL 仍遠低於題目要求的 50，表示 mixed-precision ranking 成功在提高壓縮率的同時控制模型品質損失。

相較 Case 2，Case 4 的 Compression Ratio 由 81.8739% 提升至 86.2761%，增加約 4.4022 個百分點；PPL 則由 16.1482 上升至 18.8324，增加 2.6842。兩者雖然使用相似的 GPTQ INT2／INT3 mixed precision，但 Case 4 在量化前先實際移除 MLP neurons，因此額外得到結構性壓縮，同時也引入 pruning error。這說明 Case 4 較高的壓縮率是 structured pruning 與低位元量化共同作用的結果，而較高的 PPL 則來自剪枝誤差與量化誤差的累積。

值得注意的是，Pruning Rate 22.4567% 與後續 quantization 的壓縮比例不能直接相加，因為 GPTQ 是套用在剪枝後剩餘的 weights 上。最終 86.2761% 是以原始未剪枝 FP16 Linear payload 為分母，重新計算剪枝後所有 INT2／INT3 weights、scales、zero points 與排列索引的實際 payload 所得到的結果。

整體而言，Case 4 成功同時滿足 Pruning Rate ≥ 20%、Compression Ratio ≥ 85% 與 PPL < 50。實驗結果顯示，先以 activation-aware structured pruning 移除低重要度 MLP neurons，再對縮小後的模型進行 GPTQ mixed-precision quantization，可以取得四個 cases 中最高的 Compression Ratio，同時將 PPL 維持在 20 以下。

7. Conclusion

本實驗完成四種不同限制下的 Qwen3-4B Linear compression。Case 1 使用 NF4 與少量 GPTQ 3-bit，在 75.2087% Compression Ratio 下得到最低的 PPL 14.8505；Case 2 使用 GPTQ INT2／INT3 mixed precision，將 Compression Ratio 提升至 81.8739%，PPL 為 16.1482；Case 3 使用 Activation-weighted SVD 與 INT8／FP16 mixed precision，達到 22.2727% SVD Compression Ratio、精確 50% Overall Compression Ratio，以及 PPL 25.7291；Case 4 結合 structured MLP pruning 與 GPTQ INT2／INT3，得到最高的 86.2761% Compression Ratio，PPL 為 18.8324。四個 cases 均符合各自的作業限制。

首先，我從實驗中觀察到，理論 bit-width 不能直接代表實際 Compression Ratio。量化模型除了 packed weights 外，還需要儲存 scales、zero points、codebooks、排列索引與 quantization states。例如 Case 1 的全 NF4 baseline 理論上接近 75% 壓縮，但計入額外 tensors 後實際只有 74.2022%。因此壓縮率必須根據實際儲存的 tensor payload 計算，而不能只用 4-bit、3-bit 或 2-bit 的理論比例估算。

第二，不同 Linear layers 對壓縮的敏感程度並不相同。Case 1 至 Case 4 都顯示，若使用 calibration output error／saved bytes 進行選擇，可以優先壓縮對模型輸出影響較小的 layers。例如 Case 1 只需要將 25 個 MLP Linear 改為 GPTQ 3-bit，就能跨過 75% 門檻；Case 2 則選擇 44 個 layers 使用 2-bit，而不是將全部 layers 一律降為 2-bit。這表示 mixed precision 比 uniform low-bit quantization 更能控制模型品質。

不過，calibration reconstruction error 仍只是最終 PPL sensitivity 的近似指標。部分 candidates 在局部 block evaluation 中呈現較低誤差，不代表它們一定能改善完整模型的 PPL；不同 layers 的誤差也可能在後續 blocks 中被放大或互相抵銷。因此，calibration ranking 適合用於縮小搜尋範圍與配置壓縮資源，但最終結果仍必須使用官方 WikiText-2 test evaluation 確認。

第三，模型品質不只取決於 Compression Ratio，也與壓縮誤差的形式有關。Case 3 的 Compression Ratio 只有 50%，但 PPL 25.7291，反而高於 Compression Ratio 86.2761% 的 Case 4。主要原因是 SVD 會直接捨棄原始 weight matrix 的部分子空間，造成結構性 approximation error；GPTQ 則保留完整矩陣維度，主要改變 weight 的數值精度。這表示即使壓縮率較低，若壓縮方法移除了對模型輸出重要的方向，仍可能造成較大的品質下降。

第四，結合互補的壓縮方法可以得到比單一方法更好的結果。Case 4 先以 structured pruning 實際移除低重要度 MLP neurons，再對縮小後的模型進行 GPTQ mixed-precision quantization。Pruning 負責減少模型結構與參數量，GPTQ 則進一步降低剩餘 weights 的儲存精度。兩種方法處理不同的冗餘來源，因此最終能達到四個 cases 中最高的 Compression Ratio，同時將 PPL 維持在 20 以下。

若以模型品質為最優先考量，Case 1 是最合適的策略，因為它只對少量 calibration 判定較不敏感的 MLP layers 使用 3-bit，其餘 layers 保留 NF4，最終得到最低的 PPL 14.8505。若希望在壓縮率與模型品質之間取得較簡單、穩定的平衡，Case 2 的 GPTQ INT2／INT3 mixed precision 較合適，在 81.8739% Compression Ratio 下仍可維持 PPL 16.1482。

然而，若以本作業的限制為判準，希望在滿足 PPL 要求的前提下取得最高 Compression Ratio，我認為 Case 4 的「Structured MLP Pruning + GPTQ INT2／INT3 mixed precision」是四種方法中最有效的策略。它同時達到

22.4567% Pruning Rate、86.2761% Compression Ratio 與 18.8324 PPL，不但通過 Case 4 的所有門檻，也比只使用 mixed-precision GPTQ 的 Case 2 多提供約 4.4022 個百分點的壓縮率。

整體而言，本實驗最重要的學習是：有效的 LLM compression 不是單純將所有 layers 改成更低 bit-width，而是必須同時考慮實際儲存成本、不同 layers 的敏感度、局部 reconstruction error 與最終 PPL。以 calibration data 評估 error／saved bytes，再針對不同 layers 分配 pruning width、rank 或 bit-width，能比固定且一致的壓縮設定得到更好的品質與壓縮率平衡。