Lab 2 Part 3

AdaptQuant：Hardware-Aligned Per-Tile MX Format Selection 重現

學號：314551126 姓名：林正峰

1. Method and Reproduction Boundary

本版本改用作業指定論文 AdaptQuant 的核心流程，而非前一版固定 NF4 W4A6。量化範圍為 Qwen3-4B 36 個 decoder blocks 中全部 252 個 Linear projections：q_proj、k_proj、v_proj、o_proj、gate_proj、up_proj 與 down_proj。Weight 與各 Linear 的 input activation 都套用量化；embedding、共享 lm_head 與 normalization 依助教說明排除。

甲、Per-tile MX format selection

每個 operand 依 Blackwell block-scaled MMA 的 16×32 tile 劃分。每個 tile 只計算一次 stat = log2(absmax/RMS)，再以固定門檻選擇 MXFP4、MXFP6 或 MXFP8。元素格式分別為 E2M1、E2M3 與 E4M3；每一列連續 32 個 values 共用一個 E8M0 scale。格式選擇發生在 tile 層級，不是為整層指定同一 bit-width。

乙、Frozen policy 與 target-model calibration-free

門檻不是在 Qwen3-4B 上搜尋。derive_policy.py 只在 reference model unsloth/Llama-3.1-8B（revision 3f0d51f8…）使用 WikiText-2 train 前 2048 tokens 建立 weight/activation 的 statistic-error histograms，並以 NVFP4 reconstruction error 為參考求解門檻。正式 run.sh 直接載入 frozen_policy.json，不重跑推導，也不根據 Qwen3-4B 的 activation、layer error 或 PPL 修改門檻。因此正式目標模型流程不需要 calibration dataset。

原論文以 NVFP4 parity 為 error constraint；本作業另要求 (Weight Bits + Activation Bits)/2 ≤ 5.3。為符合新規格，離線 solver 在 reference model 上使用單一 0.7 dB slack，並將 reference budget 設為 5.17 bits。這是本實作唯一的作業規格調整，且仍完全在 reference model 上決定。

丙、T4 fake quantization

NVIDIA T4 沒有 Blackwell 的原生 MX MMA。本實作依 MX grid 與 scale 規則量化後，立即反量化回 FP16 tensor，再呼叫原本 Linear operation。報告結果因此驗證的是量化數值對 PPL 的影響與 logical effective bit rate，不主張 T4 上的真實 packed checkpoint 大小或速度。

2. Result

設定	WikiText-2 PPL	Weight bits	Activation bits	(W+A)/2
原始 FP16	13.6378	16	16	16
AdaptQuant 重現	14.6440	5.045517	5.145720	5.095619

量化後 PPL 由 13.6378 上升至 14.6440，增加 1.0062（約 7.38%），仍低於 15，因此落在作業最高 performance score 級距。相較作業列出的 AdaptQuant PPL 13.98，本次 T4 fake-quant 重現高 0.6640。

甲、Effective bit rate calculation

```
MXFP4 = 4 + 8/32 = 4.25 bits/value
MXFP6 = 6 + 8/32 = 6.25 bits/value
MXFP8 = 8 + 8/32 = 8.25 bits/value
TA rule: 5-byte tile metadata is excluded

Weight tiles: 60.224130% MXFP4, 39.775870% MXFP6, 0% MXFP8
W bits = 0.60224130*4.25 + 0.39775870*6.25 = 5.045517

Activation tiles: 55.213991% MXFP4, 44.786009% MXFP6, 0% MXFP8
A bits = 0.55213991*4.25 + 0.44786009*6.25 = 5.145720

Realized Effective Bit Rate = (5.045517 + 5.145720)/2 = 5.095619 ≤ 5.3
```

3. Observation and Discussion

甲、Important observations

Qwen3-4B 的 activation tiles 使用 MXFP6 的比例（44.79%）高於 weight tiles（39.78%），使 activation effective bits 比 weight 高約 0.1002 bits。這表示依目前固定門檻，evaluation 中較多 activation tiles 的 crest-factor statistic 落在高精度區間。不過 weight 與 activation 的門檻本來就按 operand/projection 分開求解，因此不能只由比例直接斷言 activation 一定比 weight 更敏感。

最終沒有 tile 使用 MXFP8，因為 14 組 frozen rules 的第二門檻皆為 CAP。實際執行因此是 MXFP4/MXFP6 mixed precision，但程式仍完整保留 MXFP8 路徑與 bit accounting。與固定 NF4 W4A6 相比，新的 PPL 14.6440 略優於 14.6759，effective bit rate 5.095619 也低於 5.25；改善來自 tile-dependent precision allocation，而不是在 Qwen3-4B 上重新搜尋。

乙、How quantization affects model quality

MXFP4 將每個 value 限制在 E2M1 格點，且每 32 個 values 共用一個 power-of-two E8M0 scale。對 absmax/RMS 較大的 tile，少數 outliers 會放大共用 scale，使小值的可用解析度下降。AdaptQuant 以 statistic 將這些 tiles 提升為 MXFP6，增加 mantissa precision並減少 reconstruction error；其餘 tiles 留在 MXFP4，維持較低平均 bit rate。

單一 tile 的 rounding error 很小，但 252 個 weight matrices 與其 activations 都被量化，誤差會在 36 個 attention/MLP blocks 中傳播與累積，因此 PPL 仍由 13.6378 上升至 14.6440。另一方面，embedding、lm_head、normalization 與非 Linear 運算維持 FP16，也避免所有路徑同時承受低精度誤差。

丙、Difficulties encountered

- 必須固定 16×32 tile boundary；execution chunking 只能在 16-row 邊界切割，否則相同 tensor 可能因 chunk size 改變格式選擇。最後不足 16 rows 的 activation 需補零並只回傳原始 rows。
- MXFP4/6/8 的 element grid、subnormal、round-to-nearest-even、E8M0 scale 與 zero block 都要一致。過早轉成 FP16 計算 statistic 或 scale 會額外改變 quantization result。
- Activation 是 runtime operand，必須在 252 個 Linear 的 pre-hook 即時量化並累積真實 tile counts；同時不可讓 evaluation data 回頭改動 thresholds。
- 依助教最新說明，scale overhead 必須計入，但 AdaptQuant 每個 tile 的 5-byte format-tag/offset metadata 不計。本實作以實際 tile counts 計算 element+scale bits，並在 result JSON 明確記錄 metadata excluded。
- T4 fake quantization 需要先算 statistic，且同一 chunk 可能同時計算 MXFP4 與 MXFP6 reconstruction，因此完整 WikiText-2 evaluation 約需 13.7 分鐘。這是模擬成本，不等同 Blackwell 原生 kernel 的效能。

丁、Possible reasons for performance degradation

- MXFP4 tiles 的 E2M1 格點較稀疏，會產生不可避免的 rounding error。
- 32-value block 共用 scale；block 內 outlier 可能降低其他小值的相對解析度。
- 為滿足 5.3-bit 限制，reference solver 使用 0.7 dB slack，允許部分 tiles 相較 NVFP4 有較高 reconstruction error。
- 門檻由 Llama-3.1-8B 推導後固定套用；reference 與 Qwen3-4B 的各 projection 分布不完全相同，因此不會是目標模型最佳配置。
- fake quantization 重現的是數值格式，但沒有 Blackwell kernel 的實際 accumulator、packing 與 execution details，與論文 13.98 存在差距是合理的。

戊、Limitations and possible improvements

本實驗最大的限制是沒有真正 packed MX checkpoint 與 Blackwell low-precision kernel，因此無法量測論文所強調的儲存縮減與 throughput。其次，policy 只由單一 reference model 與 2048 tokens 推導；雖然符合 target-model calibration-free，但跨模型通用性仍受 reference distribution 影響。最後，0.7 dB slack 是為本作業 combined W+A bit budget 增加的限制，並非原論文的原始 NVFP4-parity設定。

可能改善方向包括：在 Blackwell 上使用真實 packed MXFP4/MXFP6 storage 與 block-scaled MMA；在不接觸 Qwen3-4B 的前提下，用更多 reference models 建立更通用的 frozen rule；或在 reference side 更精細地配置全域 bit budget。任何 threshold、precision 或 layer rule 都必須先在 reference side 固定，不能利用 Qwen3-4B calibration/PPL 搜尋，才能維持作業要求。

4. Conclusion

本次重現顯示，硬體對齊的 per-tile mixed MX selection 能在 target-model calibration-free 的前提下，比固定格式更有效地分配精度。最終 PPL 14.6440、realized effective bit rate 5.095619，通過 ≤5.3 與 PPL≤15 兩項要求。相較固定 NF4 W4A6，AdaptQuant 需要離線 reference policy 與更複雜的 runtime tile selection，但能讓高 crest-factor tiles 使用 MXFP6，其餘維持 MXFP4，得到稍好的品質與更低平均 bit rate。對本作業限制而言，AdaptQuant 版本是較貼近指定論文與硬體格式的方案；原本固定 NF4 版本則仍是更簡單、完全不依賴 reference derivation 的可靠 fallback。