Lab 2 • Part 2
Qwen3-4B 模型壓縮

學號：314551126 日期：2026-11-03 單張 NVIDIA T4

本實驗從相同原始 Qwen/Qwen3-4B 出發，依四個 case 的儲存與品質限制，分別組合 NF4、GPTQ 低位元量化、加權 SVD 與結構化 MLP 剪枝。所有 PPL 均由作業提供的 run_eval.py 計算。

1 最終結果

Case	整體壓縮率	PPL	額外條件
1	75.208743%	14.8505	CR >75%；PPL <15
2	81.873929%	16.1482	CR ≥81%；PPL <20
3	精確50%	25.7291	SVD 22.2727%；PPL <50
4	86.276105%	18.8324	剪枝 22.4567%；PPL <50

2 環境與公平比較

Python 3.11、torch 2.5.1+cu121、transformers 4.56.2、bitsandbytes 0.48.1、triton 3.1.0。四個 cases 使用相同原始模型 commit，沒有以其他 case 的量化結果作為起點。WikiText-2 train 用於校正／選擇，test 僅作最後正式評估，sequence length 固定2048。

不執行 fine-tuning、梯度訓練、推論參數 offloading、KV cache 壓縮、speculative decoding 或多 GPU model parallelism。推論都在一張 T4 上完成。

Case 1、2、4 沿用原本 checkpoint 與官方 PPL，本次只依新範圍重算大小；Case 3 保留原有 SVD 分解，重新配置 INT8／FP16 rows 並完整重跑官方 PPL。控制實驗的 CR 也已按相同範圍重算。

3 壓縮率與真實儲存

CR = 1 − compressed_linear_bytes / original_linear_bytes。依助教最後說明，目標為252個 decoder nn.Linear，分子與分母均排除 lm_head、embedding 與 normalization。原始 FP16 payload 共7,266,631,680 bytes。分子包含壓縮權重與所有新增 tensor：scales、zero points、codebooks、排列索引、bias 及 NF4 state。

計算以原始 Linear 的對應 tensor payload 為範圍；完整 checkpoint 的非 Linear 權重與檔案 header 另行記錄。程式保存後重新載入並按實際 tensor 驗證大小；統一入口也直接檢查 safetensors byte ranges，不只用理論 bit 數估算。

Case 1 • NF4＋部分 GPTQ INT3

4 方法與設定

先以 NF4＋double quantization 壓縮全部目標 Linear，再把部分 decoder MLP Linear 替換成 GPTQ 3-bit。NF4 的 scale／metadata 會使實際儲存略高於理論4-bit；因此僅採 NF4 不足以保證壓縮率嚴格大於75%。

校正從 WikiText-2 train 取32×512 tokens 估計輸入 Gram matrix，另外4×512 tokens 保留作候選比較；seed=0，區塊不重疊。GPTQ group size128、1% diagonal damping，對 gate/up/down projection 搜尋 clipping，使用 Hessian 誤差回饋。

以保留樣本比較每層 GPTQ3 與 NF4 的相對輸出誤差，依「增加的誤差／實際節省 bytes」排序，替換直到 decoder CR ≥75.2%。選擇過程不讀 test PPL。

5 結果與實際格式

項目	本次結果
GPTQ3 Linear 數	25
其餘目標 Linear	decoder packed NF4；head另存、不計CR
目標 Linear payload	1,801,489,343 bytes
壓縮率／PPL	75.208743% ／ 14.8505

INT3 每8個 unsigned codes 真正打包成3 bytes，每 group 額外儲存 FP16 scale 與 uint8 zero point。目標 decoder NF4 的 packed weights、double-quant state、codebooks 與 metadata 也納入計算；head state 排除。共享 embedding 參照同一份 packed head，不保留第二份 FP16 矩陣。

6 分析

Case 1 的品質門檻最嚴格，因此只將少量候選改成3-bit，保留大部分 NF4。候選輸出誤差比單純看權重 MSE 更能反映實際輸入分布；有些層在 GPTQ 誤差補償後甚至比 NF4 更接近原輸出，但這是校正樣本上的觀察，不代表所有文字都改善。

最終 PPL 14.8505 通過 <15，但距離門檻有限。這反映嚴格品質限制下可用的低位元空間不大；不同套件或 GPU 計算差異需要固定環境與來源 commit 控制。

Case 2 • GPTQ INT2／INT3 混合

7 方法與重要設定

以全部252個 decoder Linear 的 GPTQ 3-bit 為起點，共享 embedding／lm_head 採 packed NF4。再為各層產生2-bit候選，依保留樣本的 block 輸出誤差增量／省下 bytes 排序，配置到 decoder CR ≥81.87%。

WikiText-2 train：64×1024 tokens 估計統計、8×1024 tokens 保留比較。Group size256、act-order、1% damping、clipping ratio 1.0至0.4。Act-order 的輸入排列索引會實際保存並計入大小。

格式	Linear 數
GPTQ INT2	44
GPTQ INT3	208
NF4 head	1，共享 embedding；不計入CR

8 結果與比較

設定	CR	PPL
先前全 decoder 3-bit 控制實驗	80.6113%	15.2036
本次 INT2／INT3	81.873929%	16.1482

本次 Linear payload 為 1,317,154,816 bytes。INT2 每4個 codes 打包成1 byte；INT3 每8個 codes 打包成3 bytes。目標 decoder 的 scale、zero point、排列索引與 NF4 state 都算入分子，不以理論2／3-bit推算最終 CR。

9 分析

全3-bit控制實驗的 PPL 較低，但儲存壓縮仍未達81%。部分層改為2-bit後，以可接受的品質下降換取額外儲存節省。Block 層級比較把同一 Linear 的改動放回完整 block，較能反映 activation 經非線性與其他投影後的影響；最後仍需完整模型 PPL 驗證組合誤差。

這個方法與 Case 1 共用 GPTQ／NF4 技術，但改變精度配置與校正設定。品質要求放寬到 PPL <20，使較多低位元配置可行；並非所有層都可任意降到2-bit。

Case 3 • 加權 SVD＋INT8／FP16

10 SVD 與精度配置

校正設定為 train 64×1024 tokens，另留8×1024 tokens。對 MLP gate/up/down 的 W 與輸入 H=E[xx^T]，取 W H^(1/2) 的主要左奇異向量 U_r，形成 W≈U_r U_r^T W，儲存兩個平衡尺度後的 FP16 因子 A、B，推論直接計算 A(Bx)。

Rank 從1024開始、主要步長64。每層以候選輸出誤差對節省 bytes 建立下凸包，再按邊際成本分配 rank，直到僅靠 SVD 的 decoder 儲存減少至少22.27%。不保存推論 whitening matrix；它已融合進因子。

本次共有 69 個 Linear 分解。Rank 分布：1024×51、1088×4、1152×3、1216×4、1280×5、1344×2。其餘 Linear 保持原矩陣形式，共享 embedding／lm_head 保持 FP16。

11 精確50%的實作

助教允許整體 CR 介於49.5%與50.5%；本實作仍以精確50%建構。排除 FP16 head 後，原配置會是 55.3526%，因此本次減少 INT8 rows、恢復更多 FP16 rows，沒有只修改顯示數字。

階段	目標 Linear bytes	CR
原始 FP16	7,266,631,680	0%
僅 SVD	5,648,154,624	22.272727%
SVD＋INT8／FP16	3,633,315,840	精確50%

分解因子與其餘 decoder Linear 的一部分 rows 存為 INT8，每 row 有1個 FP16 scale；其他 rows 維持 FP16。寬度 n 的一個 INT8 row 實際節省 n−2 bytes。以輸出誤差／節省量配置後，用兩個預留 attention Linear 的有界整數方程精確收尾。所有儲存權重都參與推論，沒有無用途 padding。

整數等式：2 × 3,633,315,840 = 7,266,631,680。這是實際 payload 恰好一半，不是顯示四捨五入；SVD CR 則在量化之前獨立計算。

12 結果與分析

先前僅 SVD 控制實驗 PPL 25.8703；本次最終 PPL 25.7291，符合 <50。主要品質損失來自低 rank 近似；加上 INT8 後的差異很小，個別 PPL 波動不代表量化必然改善品質。加權分解有助於把有限 rank 用在校正輸入常見的方向，但仍無法完整保留模型行為。

Case 4 • 結構化剪枝＋INT2／INT3

13 實際刪除 MLP 結構

在 train 64×1024 tokens 收集中間 activation z=SiLU(gate(x))*up(x) 的二階矩，另留8×1024 tokens 比較候選。神經元重要度為 $E[z_j^2]$ ||down[:,j]||^2。同步刪除 gate/up 的 rows 與 down 的 columns，讓實際矩陣變小，沒有以零值 mask 充當儲存壓縮。

候選中間寬度7424、7168、6912、6656、6400；原寬度9728。對保留通道做閉式輸出補償：D_new = D_keep + D_drop H_drop,keep (H_keep,keep + λI)^−1。使用單位變異量座標與1% damping，僅採用保留樣本誤差較小的補償結果。

依候選損失／刪除權重數的下凸包配置寬度，直到原始 decoder Linear 的權重數減少至少22.45%。低 bit 量化不計為剪枝。剪枝後重新收集 GPTQ 統計，與 Case 2 不共用其 Gram matrix。

14 量化、結果與觀察

剪枝後 decoder 採 group256、act-order、1% damping 的 GPTQ INT2／INT3；61 個 Linear 為 2-bit、其餘 191 個為3-bit。共享 head 採 NF4，其權重與 state 不計入CR。刪除與 decoder 量化額外資料以相同原始 decoder Linear 分母計算，量化配置門檻為86.27%。

設定	CR	PPL
先前剪枝 FP16 控制實驗	22.4567%	16.1005
先前剪枝＋decoder INT3	84.9594%	17.5312
本次剪枝＋INT2／INT3	86.276105%	18.8324

本次物理剪枝率 22.456710%，最終 payload 997,264,896 bytes。模型載入後再次依矩陣形狀驗證剪枝數；校正使用的 indices 不需要作為推論 mask 或 gather。

剪枝先降低矩陣維度，再量化剩餘權重，兩者可疊加節省儲存。閉式補償可吸收部分相關通道的貢獻，仍無法完整恢復被刪除特徵。相較全3-bit控制實驗，混合2-bit使壓縮率達85%以上，代價是較高 PPL。剪枝配置相同時，3-bit與混合配置的主要變因是部分層改為2-bit；若比較原始 FP16 與最終模型，才同時包含剪枝與量化的影響。

整體結論、驗證與重現

15 四種配置的取捨

本次最適合嚴格品質條件的是 Case 1：大部分保留 NF4，只把校正資料顯示代價較低的層降到3-bit。若目標優先追求儲存節省、可接受較高 PPL，Case 4 的物理剪枝加低位元量化取得本次最高 CR；Case 2 則提供不改結構的中間選擇。

Case 3 的目標包含指定 SVD 比率與精確總大小，不能只選最小 checkpoint。加權 SVD 與 row 精度配置可各自滿足這兩個條件，但品質下降較明顯。不同 case 的 PPL 並不只由 CR 決定：誤差補償、被壓縮的層、矩陣 rank 與剪枝位置同樣重要。

層敏感度以校正輸出誤差排序，而非憑層號或權重大小猜測。這能配置有限儲存預算，但校正樣本有限、候選組合也不是全域最佳；train 上低誤差不保證每種領域文字都維持品質。

16 實作困難與驗證

實作中需要處理低位元打包與補充 state、act-order 逆排列、SVD 因子的記憶體 layout／動態範圍，以及精確 bytes 配置。每個最終 checkpoint 都保存後重新載入，固定8-token輸入的 logits bitwise 相同。推論僅暫時重建當前 Linear 的 FP16 權重，不持久保存全模型 FP16 副本；沒有宣稱推論加速。

run_eval.py 與 evaluate.py 保留原始 bytes。只由 wrapper 提供壓縮模型及自行計算的 compression callback，不改 PPL 流程。最終統一輸出只含四個 case 的 CR 與 PPL，安裝與執行日誌另存。

17 重現與輸出

在 Part2/ 執行 bash run.sh，或 bash 314551126_run.sh。程式自動建立 Python 3.11 環境、安裝 requirements、依序壓縮與評估四個 cases。首次需網路下載原始模型及資料；一張 T4 即可，完整候選搜尋需要較長時間與暫存磁碟。詳細指令見 README.md。

results/caseN_result.json 記錄正式 PPL 與實際儲存驗證；caseN_manifest.json 記錄配置、量化 state 格式與重載檢查。artifacts/ 是可重建輸出，不必提交大型 checkpoint；不依賴本機實驗目錄或其既有候選。

固定模型 revision：1cfa9a7208912126459214e8b04321603b3df60c
評估原始檔 SHA-256：
run_eval.py：d05ffd56d5a652d9ef81ecfd6da06d9388c05e1ea9b277de7a9a7f52ca31ea6e
evaluate.py：a57c839b46e4c5babccb74e840fbb6e44e6be80cfd15d0aa372b72da4e24c441

18 參考來源

GPTQ：Frantar et al., https://arxiv.org/abs/2210.17323
NF4 格式：Dettmers et al., QLoRA, https://arxiv.org/abs/2305.14314
加權分解思路：SVD-LLM, https://arxiv.org/abs/2403.07378
本實作採相關核心思路，未宣稱完整重現上述所有流程；不使用 LoRA 或 fine-tuning。