Lab2 Part3 314551126 林正峰

1. Method

甲、AdaptQuant Calibration-Free PTQ

本實驗依照 AdaptQuant 的概念實作 calibration-free Post-Training Quantization。量化對象為 Qwen3-4B decoder 中全部 252 個 Linear layers，包含 q_proj、k_proj、v_proj、o_proj、gate_proj、up_proj 與 down_proj。

與原本固定單一格式的量化方式不同，本方法會同時量化 Weight 與 Activation，並根據不同 tile 的數值分布，在 MXFP4、MXFP6 與 MXFP8 中選擇適合的格式。Input embedding、lm_head 與 normalization layers 不進行量化。

乙、Per-Tile MX Format Selection

Weight 與 Activation 會被切分成 16 × 32 的 tiles。對每個 tile 計算：stat = log2(absmax / RMS)。其中 absmax 為 tile 中最大的絕對值，RMS 則反映 tile 中整體數值大小。

根據預先設定的 thresholds，每個 tile 分別選擇 MXFP4、MXFP6 或 MXFP8。stat 較小的 tile 使用較低精度格式，以降低 bit 數；stat 較大的 tile 則使用較高精度格式，以降低 outlier 所造成的量化誤差。

每 32 個 values 共用一個 E8M0 scale。Weight 與 Activation 使用不同 thresholds，且不同 projection type 也有各自的 threshold。

丙、Calibration-Free Policy

本實驗的 thresholds 並不是使用目標模型 Qwen3-4B 進行 calibration 得到，而是事先使用非目標 reference model Llama-3.1-8B 推導。

Reference model 使用 WikiText-2 train 前 2048 tokens，比較不同 MX formats 的 reconstruction error，並產生 Weight 與 Activation 各 projection type 的 thresholds。完成後將設定固定於 frozen_policy.json。正式量化 Qwen3-4B 時直接使用此固定 policy，不使用 Qwen3-4B 的 calibration data、activation statistics、PPL 或 layer error 調整 thresholds，因此符合 target-model calibration-free PTQ 的要求。

2. Result

設定	Weight Effective Bits	Activation Effective Bits	(W+A)/2	WikiText-2 PPL
原始 FP16	16	16	16	13.6378
AdaptQuant reproduction	5.0455	5.1457	5.0956	14.6440

3. Observation and Discussion

甲、Experimental Observations

原始 FP16 模型的 WikiText-2 PPL 為 13.6378，套用 AdaptQuant 後為 14.6440，增加 1.0062。雖然模型品質有所下降，但 PPL 仍低於 15，因此符合本作業最高的 performance score 級距。

最終 Weight Effective Bits 為 5.0455，Activation Effective Bits 為 5.1457，平均 Realized Effective Bit Rate 為 5.0956，符合題目要求的 ≤ 5.3 bits。

在 Qwen3-4B 上，Weight tiles 約有 60.22% 使用 MXFP4、39.78% 使用 MXFP6；Activation tiles 約有 55.21% 使用 MXFP4、44.79% 使用 MXFP6。可以觀察到 Activation 使用 MXFP6 的比例較高，表示在目前 frozen policy 下，activation tiles 較常需要使用較高精度格式。

乙、Effect on Model Quality

AdaptQuant 並不是將所有 values 固定量化成相同精度，而是根據每個 16 × 32 tile 的 absmax 與 RMS 統計，選擇 MXFP4 或 MXFP6。較平滑的 tiles 使用 MXFP4，可以降低平均 bit rate；數值分布較不均勻的 tiles 則使用 MXFP6，以保留較高精度。這種 per-tile mixed precision 能避免所有 weights 與 activations 都使用低精度所造成的較大誤差，因此在 Realized Effective Bit Rate 只有 5.0956 bits 的情況下，PPL 仍能維持在 14.6440。

不過量化後的 Weight 與 Activation 都會產生 rounding error，而且誤差會經過多層 attention 與 MLP 運算持續傳播，因此最終 PPL 仍高於原始 FP16。

丙、Difficulties Encountered During Implementation

第一個困難是正確實作 16 × 32 tile-based quantization。程式需要維持固定 tile boundary，並正確處理尺寸不足 16 rows 時的 padding，避免不同執行方式改變 format selection。

第二個困難是 Activation quantization。Weight 可以在 evaluation 前一次量化完成，但 Activation 會隨每次 forward 改變，因此必須在每個 Linear 輸入前即時計算 tile statistic、選擇 MX format 並進行 fake quantization，使執行時間明顯增加。

第三個困難是確保 calibration-free 條件。Thresholds 必須在 Qwen3-4B 執行前就固定，因此本實驗先在非目標的 Llama-3.1-8B 上產生 frozen policy，正式執行 Qwen3-4B 時不再利用其 calibration data、PPL 或 layer error 修改設定。

此外，effective bit rate 的計算也必須包含每 32 values 共用的 E8M0 scale overhead，並依助教規定排除 5-byte tile metadata，才能與作業定義一致。

丁、Possible Reasons for Performance Degradation

PPL 從 13.6378 上升至 14.6440，主要可能來自 Weight 與 Activation 同時量化所產生的誤差。

MXFP4 的精度較低，當約六成 Weight tiles 與超過一半的 Activation tiles 使用 MXFP4 時，這些 rounding errors 會在 36 個 decoder blocks 中持續累積。

另外，本實驗使用的 thresholds 是由 Llama-3.1-8B 推導後直接套用至 Qwen3-4B，而不是針對 Qwen3-4B 最佳化。因此雖然符合 calibration-free 的要求，但 reference model 與 target model 的數值分布差異也可能使部分 tiles 沒有得到最適合的 precision allocation。

戊、Limitations and Possible Improvements

本實驗最大的限制是使用 fake quantization。T4 無法直接執行 Blackwell MX low-precision kernel，因此量化後仍會重建為 FP16，再使用一般 Linear operation。此結果可以評估低精度數值對 PPL 的影響，但不能代表實際 Blackwell 上的推論速度或記憶體效益。

另一個限制是目前 frozen policy 實際只使用 MXFP4 與 MXFP6，沒有使用 MXFP8。未來可以依照 AdaptQuant Algorithm 1 更完整地調整 Weight 與 Activation 的 precision budget，使不同 formats 的配置在維持 ≤ 5.3 bits 的條件下，更接近最佳的模型品質。

此外，也可以使用更多非目標 reference models 或更多 reference data 建立較具有泛化能力的 thresholds，但仍必須確保所有 policy 都在套用 Qwen3-4B 前固定，才能維持 target-model calibration-free 的要求。