Lab 2 Part 3：Calibration-Free NF4 W4A6 PTQ

學號：314551126 姓名：林正峰 模型：Qwen/Qwen3-4B 更新日期：2026-11-08

本實驗採用作業允許的替代 PTQ 方法。最終方法同時量化 decoder Linear weights 與其輸入 activations，並將所有 scale overhead 納入 realized effective bit rate。NVIDIA T4 不支援本方法的原生 NF4×INT6 kernel，因此依作業規定使用 fake quantization 評估模型品質。

1 Method

1.1 固定 NF4 W4A6

量化範圍為 Qwen3-4B 的36個 decoder blocks 中全部252個 Linear projections，包括每層的 q_proj、k_proj、v_proj、o_proj、gate_proj、up_proj 與 down_proj。Input embedding、共享 lm_head、normalization 與其他非 Linear 元件維持 FP16，且依助教說明不納入 effective-bit 計算。

項目	固定設定
Weight	NF4 4-bit；固定16個非均勻 codepoints
Activation	symmetric INT6；整數範圍[-31, 31]
Block	weight 與 activation 都是每64個連續 values 一組
Scale	FP32 計算 absmax；scale 以 FP16 儲存
量化範圍	252個 decoder Linear weights 與各 Linear 的 input activation
排除範圍	embedding、共享 lm_head、normalization、其他非 Linear 元件

1.2 Weight quantization

每64個連續 weights 為一組。先以 FP32 計算 absmax，將 scale 轉成 FP16 儲存，再以儲存後的 scale 正規化 weight，映射至最近的固定 NF4 codepoint，最後重建為 FP16。全零 block 以 scale=0 精確重建；不使用 double quantization、clipping search、逐層精度搜尋或 Hessian 補償。

Weight 流程：s = FP16(max(abs(w)))；u = w / s；code = nearest_NF4(u)；w_fake = codebook[code] × s。

1.3 Activation quantization

每個 target Linear forward 前，input activation 的最後一維以每64個 values 分組，block 不跨 token。每組以 FP32 計算 absmax，將 scale=absmax/31 轉成 FP16，再執行固定 symmetric INT6 fake quantization。

Activation 流程：s = FP16(max(abs(x))/31)；q = clamp(round(x/s), -31, 31)；x_fake = q × s。

Scale 會隨當下 activation 動態計算，但 bit-width、block size、scale precision、整數範圍與 rounding rule 都在載入 target model 前固定。動態計算當前 tensor 的 scale 不需要 calibration dataset，也不會產生跨樣本統計。

1.4 Why calibration-free?

所有規則均記錄在 nf4.py 的固定 POLICY。Weight 量化期間禁止 target-model forward；整個量化流程不讀 calibration dataset、不收集 activation statistics、不以 PPL 選擇 threshold、bit-width 或 layer allocation，也不進行 fine-tuning。WikiText-2 test 只在模型與 policy 鎖定後供官方 PPL 評估，結果不回流 quantizer。

本方法與 AdaptQuant 的主要差異是：沒有 per-tile MX format selection，而是所有 target Linear 統一使用 NF4 W4A6 block-64 格式。優點是規則簡單、可重現且完全不需 calibration；缺點是不能依 layer 或 tile 敏感度動態配置精度。

Results and Effective-Bit Accounting

2 Result

設定	WikiText-2 PPL	Realized effective bit rate
原始 FP16	13.6378	不適用
舊 NF4 W4A16 控制實驗	14.6063	10.25000007（不符合新版門檻）
最終 NF4 W4A6	14.6759	5.25000007（符合 ≤5.3）
AdaptQuant 作業比較值	13.9800	題目比較值

最終 W4A6 相較 FP16 的 PPL 增加 1.0381（約 7.61%）；相較舊 W4A16 weight-only 控制實驗只增加 0.0696。最終 PPL仍小於15，符合 performance 最高分級。

2.1 Weight effective bits

252個 target Linear 共有 3,633,315,840 個 weights。NF4 code 使用4 bits；每64個 weights 使用一個 FP16 scale，另保守計入16個 FP32 NF4 codepoints 共512 bits。

Weight total bits = 3,633,315,840 × 4 + 56,770,560 × 16 + 512 = 15,441,592,832 bits。
Weight effective bits = 15,441,592,832 / 3,633,315,840 = 4.2500001409 bits。

2.2 Activation effective bits

依252個 Linear 實際 in_features 與每次推論使用次數，每 token 共 958,464 個 activation values。Block size 64，因此共有 14,976 個 FP16 scales。

Activation total bits = 958,464 × 6 + 14,976 × 16 = 5,990,400 bits。
Activation effective bits = 5,990,400 / 958,464 = 6.25000000 bits。

2.3 Final realized effective bit rate

Realized Effective Bit Rate = (4.2500001409 + 6.25000000) / 2 = 5.2500000705 bits ≤ 5.3 bits。

上述分子、分母、scale 數量與門檻判斷均由程式依實際 model structure 計算並寫入 manifest，不是只在報告中估算。未量化的 embedding、lm_head 與 normalization 不計入。

2.4 Fake quantization

Weight 先轉成邏輯 NF4 code 再重建為 FP16 tensor；activation 在每個 target Linear 前轉成邏輯 INT6 code，再重建為 FP16 tensor。推論仍使用原始 FP16 Linear operations。此實驗驗證 W4A6 數值對 PPL 的影響，不宣稱 checkpoint 已 packed、檔案實際縮小或 T4 推論加速。

Observation and Discussion

3 Observation and Discussion

3.1 Experimental observations

最終 W4A6 PPL為 14.6759，相較 FP16 的 13.6378 增加 1.0381。舊 W4A16 僅量化 weights 時 PPL為 14.6063；加入 block-64 INT6 activation 後只再增加 0.0696，顯示6-bit activation 搭配細粒度 block scale 能保留大部分模型品質。

全部252個 Linear 的 weight reconstruction MSE為 0.0000047353。Weight scale 從 FP32 計算後以 FP16 儲存；因原始 weights 本身以 FP16 載入，這個 scale 儲存變更沒有顯著增加 weight MSE。

Checkpoint 保存後重新載入，程式重新安裝252個 activation fake-quant hooks；固定 probe 的 logits 在重載前後 bitwise identical，且 embedding 與 lm_head 仍共享權重。這表示正式 PPL差異來自固定 W4A6 數值映射，而非序列化遺失或 hook 範圍改變。

3.2 How quantization affects model quality

NF4 將每個 weight 限制為16個非均勻 codepoints之一；INT6 將每個 activation 限制為[-31,31]的63個對稱整數值之一。即使單一 block 的 rounding error很小，誤差仍會在36個 decoder blocks的 attention與MLP路徑中傳播。

Block size 64 是品質與 overhead 的折衷。較小 block 可降低 outlier 對同組 scale 的影響，但需要更多 scales。W4A6 使用 FP16 block scales後，weight為4.25 bits、activation為6.25 bits，剛好在5.3門檻內保留相對細粒度的 scale。

3.3 Difficulties encountered

第一個困難是新版規格要求 weight 與 activation 同時計算，且所有 scale overhead 都要納入。因此實作不能只標示 W4A6，而必須依252個 Linear 的實際 weight數量、in_features與執行次數計算分子分母。

第二個困難是 activation quantization 是 runtime behavior，不會隨 safetensors 權重自動保存。程式必須在原模型與重載模型上都精確安裝252個 hooks，並驗證 scope與 logits。

第三個困難是T4記憶體。2048-token activation若一次轉成 FP32 可能產生大型暫存 tensor，因此程式以 row chunks 處理；chunk size只影響暫存記憶體，不改變每64個 values 的 block邊界或量化結果。

第四個困難是證明 calibration-free。Policy會先鎖定；weight quantization期間禁止 forward；activation量化只使用當前 input block的 absmax，不保存跨樣本統計；test PPL不參與任何設定選擇。

3.4 Possible reasons for performance degradation

原因	影響
NF4 rounding	FP16 weight被映射至16個固定codepoints，產生不可避免的重建誤差。
INT6 rounding	Activation被限制為63個對稱整數值，細小差異會被捨入。
Block absmax	少數outliers會決定同一64-value block的scale，降低其餘值的解析度。
多層累積	252個Linear都使用同一低精度格式，誤差在attention與MLP中持續傳播。
無誤差補償	Calibration-free方法沒有activation-aware clipping、Hessian更新或逐層mixed precision。

3.5 Limitations and possible improvements

主要限制是 fake quantization：邏輯格式符合 W4A6，但 checkpoint與matrix multiplication仍使用 FP16，因此目前沒有真實儲存縮小或推論加速。另一限制是所有 layers都固定使用相同格式，沒有依敏感度配置 precision；本實驗也只在Qwen3-4B與WikiText-2上驗證。

未來可實作 packed NF4／INT6 storage與對應 kernel，並在不使用 target-model calibration的前提下，採用事先由其他模型推導的固定 outlier規則或 mixed-precision policy。任何改善都必須在套用 Qwen3-4B前固定，且不能以其 calibration data或PPL搜尋。

Reproducibility and Conclusion

4 Reproducibility

在 Part3 目錄執行 bash run.sh。入口會建立 Python 3.11虛擬環境、安裝 requirements.txt、重跑 FP16控制實驗、由原始 Qwen3-4B建立 W4A6模型、保存／重載、執行官方 WikiText-2 PPL並更新 results JSON。模型 revision固定為：

1cfa9a7208912126459214e8b04321603b3df60c

檔案	用途
nf4.py	固定 NF4 weight、INT6 activation、hook與bit-rate accounting
run_part3.py	模型建置、序列化驗證與官方 evaluator包裝
run_eval.py／evaluate.py	作業提供的 WikiText-2 PPL流程
results/nf4_result.json	PPL、effective-bit明細、evaluator hash
results/quantization_manifest.json	固定policy、252層統計與重載驗證

Policy SHA-256：83a3920f7f0b1080f16da9d7d8da4482c92875e585e7a262ca3565f79d5eecc0

5 Conclusion

新版規格要求 Realized Effective Bit Rate ≤5.3，舊 W4A16 的10.25 bits不再符合。本實驗改為固定 NF4 W4A6 block-64，將 weight與activation的FP16 scale overhead完整納入後得到 5.25000007 bits；官方 PPL為 14.6759，仍達到 PPL≤15最高分級。

結果顯示，在完全不使用 calibration dataset、target-model statistics或fine-tuning的條件下，block-64 INT6 activation只造成小幅額外品質損失。方法的優點是規則固定、透明且可重現；主要缺點是缺乏layer-sensitive誤差補償，且fake quantization尚未帶來實際儲存或硬體效益。

6 References

[1] Dettmers et al., QLoRA: Efficient Finetuning of Quantized LLMs. 本實驗只使用其 NF4格式，不使用LoRA或fine-tuning。
[2] bitsandbytes 0.48.1，作為固定 NF4 codepoints的交叉核對來源。
[3] Lab 2新版規格與助教說明：calibration-free、fake quantization、weight與activation effective bit rate及scale overhead。